

0

APRENDIZAJE POR REFUERZO I (CURSADO)


DOCENTE DEL CURSO

- ▶ Miguel Augusto Azar
- ▶ Ingeniero en Informática
- ▶ Especialista en Docencia Superior
- ▶ Docente e investigador
- ▶ Email: augusto.azar@gmail.com

RECURSOS VIRTUALES


► Campus virtual

<https://campusposgrado.fi.uba.ar/course/view.php?id=412>



► Repositorio

<https://github.com/ae-ar-uba/ar1/tree/ar1-2025-b3>



¿EN QUÉ CONSISTE APRENDIZAJE POR REFUERZO I?

- ▶ Consiste en el estudio y desarrollo de algoritmos inteligentes que aprenden por sí mismos (o asistidos) una determinada tarea.

CASOS DE USO

- ▶ Vehículo autónomo que aprende a conducir por sí mismo.




CASOS DE USO

- ▶ Learning to drive in a day (2018)
- ▶ DDPG (Deep Deterministic Policy Gradient)
- ▶ <https://www.youtube.com/watch?v=eRwTbRtnT1I>




CASOS DE USO

- ▶ Mano robótica que aprende a manipular objetos.




CASOS DE USO

- ▶ Learning Dexterity (OpenAI) (2018)
- ▶ <https://www.youtube.com/watch?v=jwSbzNHGfIM>





CASOS DE USO

- ▶ Brazo robótico que aprende a desplazarse hacia un punto en el espacio.




CASOS DE USO

- ▶ Setting up a Reinforcement Learning Task with a Real-World Robot. (Mahmood et al., 2018)
- ▶ https://www.youtube.com/watch?v=ZVlxt2rt1_4



CASOS DE USO

- ▶ AI Learns to Park (2019)
- ▶ PPO (Proximal Policy Optimization)
- ▶ https://www.youtube.com/watch?v=VMp6pq6_QjI



CASOS DE USO

► Deepseek-R1 (2025)



DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning

DeepSeek-AI

research@deepseek.com

Abstract

We introduce our first-generation reasoning models, DeepSeek-R1-Zero and DeepSeek-R1. DeepSeek-R1-Zero, a model trained via large-scale reinforcement learning (RL) without supervised fine-tuning (SFT) as a preliminary step, demonstrates remarkable reasoning capabilities. Through RL, DeepSeek-R1-Zero naturally emerges with numerous powerful and intriguing reasoning behaviors. However, it encounters challenges such as poor readability, and language mixing. To address these issues and further enhance reasoning performance, we introduce DeepSeek-R1, which incorporates multi-stage training and cold-start data before RL. DeepSeek-R1 achieves performance comparable to OpenAI-o1-1217 on reasoning tasks. To support the research community, we open-source DeepSeek-R1-Zero, DeepSeek-R1, and six dense models (1.5B, 7B, 8B, 14B, 32B, 70B) distilled from DeepSeek-R1 based on Qwen and Llama.

[cs.CL] 22 Jan 2025

CASOS DE USO

► Deepseek-R1 (2025)

2.2.1. Reinforcement Learning Algorithm

Group Relative Policy Optimization In order to save the training costs of RL, we adopt Group Relative Policy Optimization (GRPO) (Shao et al., 2024), which foregoes the critic model that is typically the same size as the policy model, and estimates the baseline from group scores instead. Specifically, for each question q , GRPO samples a group of outputs $\{o_1, o_2, \dots, o_G\}$ from the old policy $\pi_{\theta_{old}}$ and then optimizes the policy model π_{θ} by maximizing the following objective:

$$\mathcal{J}_{GRPO}(\theta) = \mathbb{E}[q \sim P(Q), \{o_i\}_{i=1}^G \sim \pi_{\theta_{old}}(O|q)]$$

$$\frac{1}{G} \sum_{i=1}^G \left(\min \left(\frac{\pi_{\theta}(o_i|q)}{\pi_{\theta_{old}}(o_i|q)} A_i, \text{clip} \left(\frac{\pi_{\theta}(o_i|q)}{\pi_{\theta_{old}}(o_i|q)}, 1 - \varepsilon, 1 + \varepsilon \right) A_i \right) - \beta \mathbb{D}_{KL}(\pi_{\theta} || \pi_{ref}) \right), \quad (1)$$

$$\mathbb{D}_{KL}(\pi_{\theta} || \pi_{ref}) = \frac{\pi_{ref}(o_i|q)}{\pi_{\theta}(o_i|q)} - \log \frac{\pi_{ref}(o_i|q)}{\pi_{\theta}(o_i|q)} - 1, \quad (2)$$

where ε and β are hyper-parameters, and A_i is the advantage, computed using a group of rewards $\{r_1, r_2, \dots, r_G\}$ corresponding to the outputs within each group:

$$A_i = \frac{r_i - \text{mean}(\{r_1, r_2, \dots, r_G\})}{\text{std}(\{r_1, r_2, \dots, r_G\})}. \quad (3)$$


CASOS DE USO

► LLMs mejorados con Aprendizaje por Refuerzo (Wang et al., 2024)

RL Enhanced LLMs	Organization	# Params	RL Methods
DeepSeek-R1 (DeepSeek-AI et al., 2025)	 deepseek	671B-A31B	RL through CoT
Kimi-k1.5 (Team et al., 2025)	 Moonshot AI	-	RL through CoT
o1 (OpenAI, 2024b)	 OpenAI	-	RL through CoT
Hermes 3 (Teknium et al., 2024)	 NOUS RESEARCH	8B, 70B, 405B	DPO
Athene-70B (Nexusflow, 2024)	 Nexusflow	70B	RLHF
Starling-7B (Zhu et al., 2024)	 Berkeley UNIVERSITY OF CALIFORNIA	7B	RLAIF, PPO
Gemma2 (Team et al., 2024b)	 Google	2B, 9B, 27B	RLHF
Qwen2 (Yang et al., 2024a)	 Alibaba	(0.5-72)B, 57B-A14B	DPO
Llama 3 (Dubey et al., 2024)	 Meta	8B, 70B, 405B	DPO
Nemotron-4 340B (Adler et al., 2024)	 NVIDIA	340B	DPO, RPO
ChatGLM (GLM et al., 2024)	 ZHIPU AI	6B, 9B	ChatGLM-RLHF
DeepSeek-V2 (Liu et al., 2024a)	 deepseek	236B-A21B	GRPO
Phi-3 (Abdin et al., 2024)	 Microsoft	3.8B, 7B, 14B	DPO
Zephyr (HuggingFaceH4, 2024)	 Argilla	141B-A39B	ORPO
Reka (Team et al., 2024c)	 Reka	7B, 21B	RLHF, PPO
Claude 3 (Anthropic, 2024)	 ANTHROPIC	-	RLAIF
InternLM2 (Cai et al., 2024)	 上海人工智能实验室 Shanghai Artificial Intelligence Laboratory	1.8B, 7B, 20B	RLHF, PPO
Gemini (Team et al., 2023)	 Google	-	RLHF
GPT-4 (OpenAI, 2023)	 OpenAI	-	RLHF, PPO, RBRM
Instruct-GPT (Ouyang et al., 2022)	 OpenAI	1.3B, 6B, 175B	RLHF, PPO

TÉCNICAS DE RL A ABORDAR EN EL CURSO

- ▶ Métodos de Monte Carlo
- ▶ Q-Learning
- ▶ Deep Q-Network
- ▶ Actor-Critic



TEMAS A ABORDAR EN EL CURSO

- ▶ **Introducción.** Concepto de Aprendizaje por Refuerzo. Agente. Entorno. Acciones. Recompensa / penalización. Estados. Política. Rendimiento esperado. Gráfico de convergencia. Función de valor. Exploración y Explotación. Cuando usar RL.
- ▶ **Proceso de decisión de Markov.** Modelo matemático. Proceso estocástico. Variable aleatoria. Cadenas de Markov. Propiedad markoviana. Probabilidad de transición estacionaria. Probabilidad de transición de 1 paso y N pasos. Matriz de transición. Diagrama de transición de estados. Proceso de decisión de Markov. Modelo matemático de un MDP. Tasa de descuento. Tareas episódicas. Tareas continuas. Estado absorbente. Valor de un estado. Esperanza matemática. Ecuación de Bellman. Dinámica del entorno.
- ▶ **Programación dinámica.** Evaluación de la política. Funciones de valor. Valor de una acción. Ecuación de optimalidad de Bellman. Mejora de la política. Política óptima. Teorema de mejora de políticas. Política greedy. Iteración de la política. Iteración de valor. Iteración de la política general (GPI). Clasificación de técnicas de RL. Model-based. Model-free.
- ▶ **Métodos de Monte Carlo.** Monte Carlo de primera visita. Monte Carlo de cada visita. Bootstrapping. Exploring Starts. Control Monte Carlo. Algoritmos on-policy y off-policy. Política objetivo. Política de comportamiento. Soft policies. Política Epsilon-Greedy. GLIE. Muestreo por importancia (IS) ordinario y ponderado.
- ▶ **Métodos de diferencia temporal.** TD(0). Tasa de aprendizaje. Error TD. Error de Monte Carlo. SARSA. Función Q. Q-Learning. Tabla Q.
- ▶ **Bibliotecas para aprendizaje por refuerzo.** MiniHack. PettingZoo. MuJoCo. Gymnasium. Métodos make(), reset(), sample(), step(), render(). Implementación de Gymnasium con Q-Learning. Modificación de recompensas. Directa y Wrapper. Entornos clásicos de Gymnasium. AgileRL. CleanRL. RLib. Stable Baselines 3. Métodos learn() y predict().
- ▶ **Deep Q-Network.** El problema de Q-Learning. DQN inicial. Función de pérdida. Arquitectura de DQN. Target network. Buffer replay. Variantes de DQN. Double Q-Network. Dueling Q-Network. DQN categórica. Rainbow DQN.
- ▶ **Métodos de Gradiente de Política.** Cómo funcionan. Espacio de las acciones. Tipos de políticas. Función objetivo $J(\Theta)$. Caso discreto. Caso continuo. Actualización de Θ . Teorema de gradiente de política. RENFORCE. REINFORCE con Baseline. Actor-Critic.

CURSADO

- ▶ Parte 1 (~ 80 min.)
- ▶ Break (~ 10-20 min.)
- ▶ Parte 2 (~ 80 min.)



FACULTAD DE INGENIERÍA

EVALUACIÓN

- ▶ Se aprueba la materia implementando 1 desafío práctico presentado en forma:
 - ✓ Individual.
 - ✓ Grupal (hasta 3 integrantes).
- ▶ La entrega consta de:
 - ✓ Informe explicativo de al menos 3 carillas (.pdf).
 - ✓ Código fuente en Python (.py, .ipynb, etc.) transcripto parcialmente en el informe y completo en un repositorio (el enlace al repositorio debe proporcionarse en el informe).
- ▶ La modalidad de entrega se realizará:
 - ✓ Durante la cursada o al final subiendo el .pdf al campus de la FIUBA.
 - ✓ Sin exposición en la última clase.
- ▶ Los desafíos son abiertos. El estudiante o el grupo elige un caso de uso según una o varias de las técnicas de Aprendizaje por Refuerzo vistas durante la cursada y elabora el desafío práctico.

REFERENCIAS BIBLIOGRÁFICAS Y WEB (I)

- ▶ S. Wang, S. Zhang, J. Zhang, R. Hu, X. Li, T. Zhang, et al., "Reinforcement Learning Enhanced LLMs: A Survey" arXiv preprint arXiv:2412.10400, 2024.
- ▶ J. Schulman, F. Wolski, P. Dhariwal, A. Radford, and O. Klimov, "Proximal Policy Optimization Algorithms," arXiv preprint arXiv:1707.06347, 2017.
- ▶ Hillier, F. S. Lieberman, G. J. (2010). Introducción a la Investigación de Operaciones.
- ▶ D. Guo et al., "DeepSeek-R1: Incentivizing reasoning capability in LLMs via reinforcement learning," arXiv preprint arXiv:2501.12948, 2025.
- ▶ <https://www.youtube.com/watch?v=eRwTbRtnT1I> (Learning to drive in a day)
- ▶ A. Kendall et al., "Learning to drive in a day," 2019 International Conference on Robotics and Automation (ICRA), Montreal, QC, Canada, 2019, pp. 8248-8254, doi: 10.1109/ICRA.2019.8793742. <https://ieeexplore.ieee.org/abstract/document/8793742>
- ▶ https://www.youtube.com/watch?v=VMp6pq6_QjI (AI Learns to Park - Deep Reinforcement Learning)
- ▶ Mahmood, A. R., Korenkevych, D., Komer, B. J., & Bergstra, J. (2018, October). Setting up a reinforcement learning task with a real-world robot. In 2018 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS) (pp. 4635-4640). IEEE.