

1


INTRODUCCIÓN A APRENDIZAJE POR REFUERZO

¿QUÉ ES APRENDIZAJE POR REFUERZO?




¿QUÉ ES APRENDIZAJE POR REFUERZO?

- ▶ **Aprendizaje por refuerzo** (o Reinforcement Learning) es una técnica de Machine Learning que consiste en un algoritmo en el que uno o varios **agentes** deben aprender un comportamiento a través de interacciones de prueba y error con un **entorno**.



¿QUÉ ES APRENDIZAJE POR REFUERZO?

- ▶ Por cada **acción** que realiza el agente recibe:
 - ✓ Puntaje positivo (o **recompensa**) si la acción es correcta.
 - ✓ Puntaje negativo (o **penalización**) si comete un error.
- ▶ El objetivo del agente es **maximizar la suma de recompensas**.




¿QUÉ ES APRENDIZAJE POR REFUERZO?

- ▶ El **agente** es una entidad que percibe el **estado** del entorno y toma decisiones (**acciones**) para maximizar una **recompensa** a lo largo del tiempo.
- ▶ Agente: Carrito



¿QUÉ ES APRENDIZAJE POR REFUERZO?

- ▶ El **entorno** es todo lo que rodea al **agente** y con el cual el agente interactúa.
- ▶ Entorno: Gridworld 8x8




¿QUÉ ES APRENDIZAJE POR REFUERZO?

- ▶ El **estado** representa toda la información relevante sobre el **entorno** en un momento. El **agente** necesita conocer el estado para tomar decisiones.
- ▶ Estado: casilla (3, 4)



¿QUÉ ES APRENDIZAJE POR REFUERZO?

- ▶ Las **acciones** son las decisiones que el **agente** puede tomar en cualquier **estado** dado.
- ▶ Las acciones pueden ser: Discretas o Continuas.
- ▶ Acciones en un Gridworld: Subir, Bajar, Derecha, Izquierda.
- ▶ Acciones en un robot: rotar el efector final (roll, pitch, yaw) → balanceo, cabeceo o guiñada un ángulo de 10.3 grados.



¿QUÉ ES APRENDIZAJE POR REFUERZO?

- ▶ La **recompensa** (o **refuerzo**) es un puntaje que le indica al **agente** cuán buena es la **acción** que realizó en relación con el objetivo.
- ▶ Recompensas:
 - ✓ -0.1 por cada avance sobre superficie plana.
 - ✓ -0.2 por cada avance sobre una pendiente.
 - ✓ -5 por caer en un Bunker.
 - ✓ +10 por llegar al Green.



¿DE QUÉ MANERA EL AGENTE DECIDE UNA ACCIÓN?

- ▶ Para decidir una determinada **acción** el agente utiliza lo que se conoce como **política** del agente.
- ▶ La **política** es la probabilidad de que el agente elija una determinada acción desde un determinado **estado**.
- ▶ La **política** es la estrategia del agente.



¿CÓMO SÉ QUE EL AGENTE YA APRENDIÓ?



- ▶ La meta del agente es **aprender una política** y para ello debe **maximizar la recompensa acumulada** que recibe en el largo plazo. (Sutton et al., 2018)
- ▶ Si la secuencia de recompensas recibidas después del paso de tiempo t se denota $R_{t+1}, R_{t+2}, R_{t+3}, \dots$ y si se busca **maximizar el rendimiento esperado** G_t , entonces G_t se define como una función específica de la secuencia de recompensas.
- ▶ En el caso más simple, el **rendimiento** es la suma de las recompensas:

$$G_t = R_{t+1} + R_{t+2} + R_{t+3} + \dots + R_T$$

- ▶ Donde T es el paso temporal final.


¿CÓMO SÉ QUE EL AGENTE YA APRENDIÓ?

- ▶ Cuando hay estabilidad de la recompensa acumulada (Cumulative Reward).
- ▶ La estabilidad del rendimiento se detecta mediante un Gráfico de Convergencia.






¿CÓMO SÉ QUE EL AGENTE YA APRENDIÓ?

- ▶ Cuando el algoritmo solo **explora lo aprendido**.
- ▶ La **exploración** es el proceso de búsqueda amplia en el espacio de búsqueda para descubrir diferentes regiones que pueden contener soluciones prometedoras.
- ▶ La **explotación** es el proceso de centrarse y mejorar soluciones que ya se sabe que son buenas o prometedoras.





¿CÓMO SÉ QUE EL AGENTE YA APRENDIÓ?

- ▶ Cuando se alcanza o supera el **desempeño comparado con una referencia** (Benchmarking).
- ▶ Si el desempeño del agente se aproxima o alcanza un umbral comparado con una solución de referencia o el rendimiento de un agente humano o experto en el entorno, puede ser una señal de que el aprendizaje es suficiente.



¿CÓMO SÉ QUE EL AGENTE YA APRENDIÓ?

- ▶ Cuando el **comportamiento en una simulación realista** es la esperada.
- ▶ Si el agente es capaz de realizar sus tareas de manera competente en simulaciones o entornos lo suficientemente realistas y no muestra una disminución en el rendimiento, entonces el agente puede considerarse listo para ser "desplegado" o interrumpir el entrenamiento.
- ▶ Aprendizaje por imitación (IL) (Russell, 1998) o Programming by Demonstration (PbD) (Cypher et al., 1993) o learning from demonstration (LfD) (Schaal, 1997).
- ▶ Behavioral Cloning (BC) (Bain et al., 1999) + Reinforcement Learning (RL).
- ▶ Aprendizaje por Refuerzo Inverso (IRL), (Ng et al., 2000).



DESPLIEGUE

DESPLIEGUE

- ▶ Sim-to-Real Transfer (Simulation-to-Reality)
 - ✓ Agente físico y Entorno físico
- ▶ Sim-to-Deployment (o Simulated-to-Production)
 - ✓ Agente virtual y Entorno no físico
- ▶ Hybrid Deployment
 - ✓ Agente físico/Entorno virtual o Agente virtual/Entorno físico

DESPLIEGUE

- ▶ **Sim-to-Real Transfer** (Simulation-to-Reality)

- ✓ Agente físico y Entorno físico

- ▶ Sim-to-Deployment (o Simulated-to-Production)

- ✓ Agente virtual y Entorno no físico

- ▶ Hybrid Deployment

- ✓ Agente físico/Entorno virtual o Agente virtual/Entorno físico

SIM-TO-REAL TRANSFER

- ▶ **Objetivo.** Entrenar un agente en un entorno simulado (rápido, seguro, económico) y luego transferir esa política aprendida a un sistema **físico** real.

- ✓ Robot
- ✓ Dron
- ✓ Brazo robótico
- ✓ Vehículo autónomo



DESPLIEGUE

- ▶ Sim-to-Real Transfer (Simulation-to-Reality)
 - ✓ Agente físico y Entorno físico
- ▶ **Sim-to-Deployment** (o Simulated-to-Production)
 - ✓ Agente virtual y Entorno no físico
- ▶ Hybrid Deployment
 - ✓ Agente físico/Entorno virtual o Agente virtual/Entorno físico

SIM-TO-DEPLOYMENT

- ▶ **Objetivo.** Entrenar un agente RL en un entorno controlado o sintético (ej. simulador de conversaciones, entornos sintéticos de preguntas) y luego se implementa en un entorno real de producción, por ejemplo:
 - ✓ LLMs (generación de texto, diálogo, razonamiento)
 - ✓ Chatbots reales o asistentes virtuales (entornos abiertos con humanos).
 - ✓ Motores de recomendación online (deciden qué mostrar al usuario real).
 - ✓ Juegos multijugador reales.
 - ✓ Agentes web o Modelos que interactúan con APIs externas (navegan, consultan APIs, extraen datos).
 - ✓ Trading algorítmico (toman acciones financieras en entornos reales)
- ▶ En estos casos, el entorno no es físico pero sí cambia radicalmente respecto al entorno de entrenamiento.



DESPLIEGUE

- ▶ Sim-to-Real Transfer (Simulation-to-Reality)
 - ✓ Agente físico y Entorno físico
- ▶ Sim-to-Deployment (o Simulated-to-Production)
 - ✓ Agente virtual y Entorno no físico
- ▶ **Hybrid Deployment**
 - ✓ Agente físico/Entorno virtual o Agente virtual/Entorno físico

HYBRID DEPLOYMENT

- ▶ Smart grids (ajuste de consumo eléctrico en tiempo real)
- ▶ Control industrial (sistemas de producción o refrigeración)
- ▶ Juegos con jugadores humanos (agentes RL que se enfrentan a personas)
- ▶ Edificios inteligentes (decisiones de climatización, energía, iluminación)



¿CUÁNDO USAR RL?

- ▶ Problemas de toma de decisiones **secuenciales**: es decir, si existen decisiones interdependientes (ajedrez, robot que aprende a caminar).
- ▶ **Entornos dinámicos** o inciertos: si el entorno es cambiante y el agente debe adaptarse en tiempo real (control de tráfico en una ciudad, gestión de inventarios en un almacén, reposición en góndolas).
- ▶ **No hay datos etiquetados**: si $\exists$ carencia de datasets para entrenar un modelo supervisado pero se puede definir una función de recompensa (entrenar un agente para que aprenda a conducir un automóvil autónomo).
- ▶ Problemas con **recompensas retardadas**: es decir, cuando las acciones del agente tienen consecuencias a cierto plazo (planificación financiera, trading, estrategias de marketing).

¿CUÁNDO NO USAR RL?

- ▶ Problemas **estáticos** o de una sola decisión: el problema no implica una secuencia de decisiones (ej. clasificación de imágenes).
- ▶ **Datos etiquetados disponibles**: si se dispone de datasets etiquetados es mejor usar aprendizaje supervisado (ej. predicción de precios de viviendas).
- ▶ Existen **alternativas más eficientes**: métodos mas simples tales como búsquedas heurísticas o metaheurísticas.

REFERENCIAS BIBLIOGRÁFICAS Y WEB (I)

- ▶ S. Wang, S. Zhang, J. Zhang, R. Hu, X. Li, T. Zhang, et al., "Reinforcement Learning Enhanced LLMs: A Survey," arXiv preprint arXiv:2412.10400, 2024.
- ▶ J. Schulman, F. Wolski, P. Dhariwal, A. Radford, and O. Klimov, "Proximal Policy Optimization Algorithms," arXiv preprint arXiv:1707.06347, 2017.
- ▶ Hillier, F. S. Lieberman, G. J. (2010). Introducción a la Investigación de Operaciones.
- ▶ D. Guo et al., "DeepSeek-R1: Incentivizing reasoning capability in LLMs via reinforcement learning," arXiv preprint arXiv: 2501.12948, 2025.
- ▶ R. S. Sutton and A. G. Barto, Reinforcement Learning: An Introduction, 2nd ed. Cambridge, MA, USA: MIT Press, 2018.
- ▶ Cypher, A., & Halbert, D. C. (Eds.). (1993). Watch what I do: programming by demonstration. MIT press. ISO 690.
- ▶ Bain, M. and Sommut, C., 1999. A framework for behavioural cloning. Machine Intelligence 15, 15:103.
- ▶ Schaal, S. Learning from demonstration. In Advances in neural information processing systems, pages 1040-1046, 1997.
- ▶ S. Russell, "Learning agents for uncertain environments (extended abstract)," Proceedings of the 11th Annual Conference on Computational Learning Theory (COLT'98), Madison, WI, USA, 1998, pp. 101-103. doi: 10.1145/279943.279964.
- ▶ Ng, A. Y., & Russell, S. (2000). "Algorithms for inverse reinforcement learning." Proceedings of the Seventeenth International Conference on Machine Learning (ICML), vol. 1, no. 2, p. 2.

REFERENCIAS BIBLIOGRÁFICAS Y WEB (II)

- ▶ Howard, R. A. (1960). Dynamic programming and Markov processes.
- ▶ Puterman, M. L. Markov Decision Processes: Discrete Stochastic Dynamic Programming. Wiley (1994).
- ▶ Bellman, R. E. Dynamic Programming. Princeton University Press (1957).
- ▶ Zhao, W., Queralta, J. P., & Westerlund, T. (2020, December). Sim-to-real transfer in deep reinforcement learning for robotics: a survey. In 2020 IEEE symposium series on computational intelligence (SSCI) (pp. 737-744). IEEE.