

1

PROCESO DE DECISIÓN DE MARKOV


¿CÓMO CONSTRUYO EL MODELO MATEMÁTICO DEL AR?

Ejemplo del clima:

► La probabilidad de que mañana esté **seco** es:

✓ 0.8 si hoy está seco.


✓ 0.6 si hoy llueve.



¿CÓMO CONSTRUYO EL MODELO MATEMÁTICO DEL AR?

- ▶ La evolución del clima para cada día t es: $t=0,1,2,\dots$
- ▶ El **estado** del sistema en cada día t :
 - ✓ Estado 0 = si el día t es seco.
 - ✓ Estado 1 = si el día t es lluvioso.
- ▶ Para $t = 0, 1, 2, \dots$, la **variable aleatoria** X_t toma los valores:


$$X_t = \begin{cases} 0 & \text{si día } t \text{ es seco} \\ 1 & \text{si día } t \text{ es lluvioso} \end{cases}$$



- ▶ La evolución del clima día tras día es un **proceso estocástico**.
- ▶ El **proceso estocástico** $\{X_t\} = \{X_0, X_1, X_2, \dots\}$ proporciona una representación matemática de la forma en que evoluciona el clima a través del tiempo.



PROCESOS ESTOCÁSTICOS

- ▶ Un **proceso estocástico** se define como una colección indexada de variables aleatorias $\{X_t\}$, donde el índice t toma valores de un conjunto T dado.
- ▶ T se considera el conjunto de enteros no negativos mientras que X_t representa una característica de interés cuantificable en el tiempo t .
- ▶ Por ejemplo, X_t puede representar los **niveles de inventario al final de la semana t** .



PROCESOS ESTOCÁSTICOS

- ▶ Los **procesos estocásticos** describen el comportamiento de un sistema en operación durante algunos periodos.
- ▶ La condición actual del sistema puede estar en una de $M + 1$ categorías mutuamente excluyentes llamadas **estados**.
- ▶ Por conveniencia en la notación, estos estados se etiquetan $0, 1, 2, \dots, M$.
- ▶ La **variable aleatoria** X_t representa el estado del sistema en el tiempo t , de manera que sus únicos valores posibles son $0, 1, \dots, M$.
- ▶ El **proceso estocástico** $\{X_t\} = \{X_0, X_1, X_2, \dots\}$ proporciona una **representación matemática de la forma en que evoluciona la condición del sistema físico a través del tiempo**.
- ▶ Estos tipos de procesos se conocen como **procesos estocásticos de tiempo discreto con espacio de estados finito**.



CADENAS DE MARKOV

CADENAS DE MARKOV

$$X_t = \begin{cases} 0 & \text{si día } t \text{ es seco} \\ 1 & \text{si día } t \text{ es lluvioso} \end{cases}$$

$$P\{X_{t+1} = 0 \mid X_t = 0\} = 0.8,$$

$$P\{X_{t+1} = 0 \mid X_t = 1\} = 0.6$$



- ▶ La probabilidad condicional de cualquier “evento” futuro dado cualquier “evento” pasado y el estado actual $X_t = i$, es independiente de los eventos pasados y **sólo depende del estado actual** del proceso.
- ▶ Una **cadena de Markov** es un modelo matemático que describe un proceso estocástico (aleatorio) donde el futuro depende solo del estado actual, y no del pasado.

CADENAS DE MARKOV

- Se dice que un proceso estocástico $\{X_t\}$ tiene la propiedad markoviana (es una "cadena de Markov" o "proceso de Markov" o "tiene memoria cero") si:

$$P\{X_{t+1} = j \mid X_0 = k_0, X_1 = k_1, \dots, X_{t-1} = k_{t-1}, X_t = i\} = P\{X_{t+1} = j \mid X_t = i\},$$

para $t = 0, 1, \dots$ y toda sucesión $i, j, k_0, k_1, \dots, k_{t-1}$.

$$X_t = \begin{cases} 0 & \text{si día } t \text{ es seco} \\ 1 & \text{si día } t \text{ es lluvioso} \end{cases}$$

$$P\{X_{t+1} = 0 \mid X_t = 0\} = 0.8,$$

$$P\{X_{t+1} = 0 \mid X_t = 1\} = 0.6$$



Andrey Markov


CADENAS DE MARKOV

$$\begin{aligned} p_{00} &= P\{X_{t+1} = 0 \mid X_t = 0\} = 0.8, \\ p_{10} &= P\{X_{t+1} = 0 \mid X_t = 1\} = 0.6 \end{aligned}$$

- ▶ para todo $t = 1, 2, \dots$, éstas probabilidades se conocen como las **probabilidades de transición estacionarias**.
- ▶ Las probabilidades condicionales $P\{X_{t+1} = j \mid X_t = i\}$ de una cadena de Markov se llaman **probabilidades de transición (de un paso)** si para cada i y j ,

$$P\{X_{t+1} = j \mid X_t = i\} = P\{X_1 = j \mid X_0 = i\}, \text{ para todo } t=1,2,\dots,$$
- ▶ entonces se dice que las probabilidades de transición (**de un paso**) son estacionarias.
- ▶ Si a t sumamos cualquier entero n ($n = 0, 1, 2, \dots$) estamos frente a una **probabilidad de transición de n pasos**.


$$P\{X_{t+n} = j \mid X_t = i\} = P\{X_n = j \mid X_0 = i\}$$



CADENAS DE MARKOV

$$p_{00} = P\{X_{t+1} = 0 \mid X_t = 0\} = 0.8,$$
$$p_{10} = P\{X_{t+1} = 0 \mid X_t = 1\} = 0.6$$


► $p_{01} = ?$



CADENAS DE MARKOV

$$p_{00} = P\{X_{t+1} = 0 \mid X_t = 0\} = 0.8,$$
$$p_{10} = P\{X_{t+1} = 0 \mid X_t = 1\} = 0.6$$

► $p_{11} = ?$



CADENAS DE MARKOV

$$\begin{aligned} p_{00} + p_{01} &= 1 & \text{entonces } p_{01} &= 1 - 0.8 = 0.2, \\ p_{10} + p_{11} &= 1 & \text{entonces } p_{11} &= 1 - 0.6 = 0.4, \end{aligned}$$


La **matriz de transición** es entonces:

$$\mathbf{P} = \begin{array}{c} \text{Estado} \quad 0 \quad 1 \\ \begin{array}{c} 0 \\ 1 \end{array} \begin{bmatrix} p_{00} & p_{01} \\ p_{10} & p_{11} \end{bmatrix} \end{array} = \begin{array}{c} \text{Estado} \quad 0 \quad 1 \\ \begin{array}{c} 0 \\ 1 \end{array} \begin{bmatrix} 0.8 & 0.2 \\ 0.6 & 0.4 \end{bmatrix}$$

En forma genérica tendremos:


$$\sum_{j=0}^M p_{ij}^{(n)} = 1 \quad \text{para toda } i; n = 0, 1, 2, \dots$$

$$\mathbf{P}^{(n)} = \begin{array}{c} \text{Estado} \quad 0 \quad 1 \quad \dots \quad M \\ \begin{array}{c} 0 \\ 1 \\ \vdots \\ M \end{array} \begin{bmatrix} p_{00}^{(n)} & p_{01}^{(n)} & \dots & p_{0M}^{(n)} \\ p_{10}^{(n)} & p_{11}^{(n)} & \dots & p_{1M}^{(n)} \\ \dots & \dots & \dots & \dots \\ p_{M0}^{(n)} & p_{M1}^{(n)} & \dots & p_{MM}^{(n)} \end{bmatrix} \end{array}$$



CADENAS DE MARKOV


- ▶ Diagrama de transición de estados del ejemplo del clima.
- ▶ Cadena de Markov: 0, 1, 1, 0, 0, 0, 1, ...



CADENAS DE MARKOV



- Matriz de transición de estados y diagrama de transición de estados de un fabricante de un producto. (Howard, 1960)

$$\mathbf{P} = [p_{ij}] = \begin{bmatrix} \frac{1}{2} & \frac{1}{2} \\ \frac{2}{5} & \frac{3}{5} \end{bmatrix}$$




CADENAS DE MARKOV

- Matriz de transición de estados y diagrama de transición de estados del ejemplo de inventarios.

$$P = \begin{array}{c|cccc} \text{Estado} & 0 & 1 & 2 & 3 \\ \hline 0 & 0.080 & 0.184 & 0.368 & 0.368 \\ 1 & 0.632 & 0.368 & 0 & 0 \\ 2 & 0.264 & 0.368 & 0.368 & 0 \\ 3 & 0.080 & 0.184 & 0.368 & 0.368 \end{array}$$


CADENAS DE MARKOV



- ▶ Diagrama de transición de estados de un robot de limpieza del hogar.



PROCESOS DE DECISIÓN DE MARKOV (MDP)


PROCESOS DE DECISIÓN DE MARKOV (MDP)

- ▶ Una **Maquina de estados finitos** (FSM) describe un proceso determinista. Tiene un número finito de estados, transiciones entre ellos, y reglas que definen como se pasa de uno a otro con base en una entrada.
- ▶ Un **Proceso de Decisión de Markov** describe un proceso estocástico.




PROCESOS DE DECISIÓN DE MARKOV (MDP)

- Supongamos que en una **cadena de Markov de M estados** se obtiene cierta ganancia cuando se hace una transición del estado i al estado j .
- El **proceso de Markov** ahora genera una secuencia de **recompensas** a medida que hace transiciones de estado a estado.



PROCESOS DE DECISIÓN DE MARKOV (MDP)

- ▶ Un proceso de decisión de Markov es un proceso de control estocástico de tiempo discreto donde los estados son en parte aleatorios y en parte bajo el control de un tomador de decisiones (decision maker).
- ▶ El DM es un agente que toma **acciones** en cada estado.




MODELO MATEMÁTICO DE UN MDP

► Formalmente, un MDP es una tupla $M = \langle S, A, \Phi, R \rangle$ (Puterman, 1994)


donde existe:

- ✓ Un conjunto finito de estados $S : \{s_1, \dots, s_n\}$, donde s_t denota el estado $s \in S$ al tiempo t .
- ✓ Un conjunto finito de acciones que pueden depender de cada estado, $A(s)$, donde $a_t \in A(s)$ denota la acción realizada en un estado s en el tiempo t .
- ✓ Una función de transición de estados dada como una distribución de probabilidad ($P^{a_{ss'}}$) que denota la probabilidad de llegar al estado $s' \in S$ dado que se tomó la acción $a \in A(s)$ en el estado $s \in S$, que también denotaremos como $\Phi(s, a, s')$.
- ✓ Una función de recompensa ($R^{a_{ss'}}$) que devuelve un número real indicando lo deseado de estar en un estado $s' \in S$ dado que en el estado $s \in S$ se realizó la acción $a \in A(s)$. La recompensa $R(s, a)$ es el valor que un agente recibe por realizar una acción a en el estado s . Si R es positivo (recompensa) o negativo o cero (penalización).



RECOMPENSA

- ▶ Supongamos que un robot busca una batería en un laberinto.
- ▶ Las recompensas recibidas después de un tiempo t se denotan como: $r_{t+1}, r_{t+2}, r_{t+3}, \dots$, lo que se quiere es **maximizar la recompensa total recibida.**




RECOMPENSA

- Podemos calcular la recompensa R_t de 2 formas:

$$R_t = r_{t+1} + r_{t+2} + r_{t+3} + \dots + r_T$$


$$R_t = r_{t+1} + \gamma r_{t+2} + \gamma^2 r_{t+3} + \dots = \sum_{k=0}^{\infty} \gamma^k r_{t+k+1}$$

- donde γ es la tasa de descuento, siendo $\gamma \in [0, 1)$.




RECOMPENSA

- ▶ Si el robot no usa tasa de descuento ($\gamma=1$), podría aprender rutas más largas porque **todas las recompensas futuras valen lo mismo**.
- ▶ Si el robot usa tasa de descuento ($0 \leq \gamma < 1$), aprenderá a llegar más rápido, ya que **las recompensas lejanas valen menos**.
- ▶ γ ayuda a maximizar la recompensa de manera más eficiente.
- ▶ Si no usáramos **tasa de descuento**, el robot podría:
 - ✓ Perder tiempo en rutas largas.
 - ✓ Quedarse atrapado en bucles infinitos si el problema no tiene un final.
- ▶ La **tasa de descuento** balancea la recompensa inmediata con la futura, favoreciendo decisiones óptimas en el tiempo.
- ▶ La **tasa de descuento** γ es un factor que determina cuánta importancia se le da a las recompensas futuras en comparación con las recompensas inmediatas.




TAREAS EPISÓDICAS Y TAREAS CONTINUAS

- ▶ Ejemplo de Frozen Lake y de Ajedrez



TAREAS EPISÓDICAS Y TAREAS CONTINUAS

- ▶ En Frozen Lake el personaje realiza una **tarea episódica** porque el episodio termina al caer al lago (por debilidad del hielo) o llegar a la meta.
- ▶ El juego de ajedrez es una **tarea episódica** porque finaliza cuando un jugador gana, pierde, empata o abandona.



TAREAS EPISÓDICAS Y TAREAS CONTINUAS

- ▶ La tarea de un agente (o bot) que hace trading en la bolsa de comercio es una **tarea continua**.



TAREAS EPISÓDICAS Y TAREAS CONTINUAS

- ▶ Si el agente sigue funcionando para siempre (tarea continua), la suma de las recompensas sería infinita, lo cual es un problema matemático.

- ▶ Ejemplo sin tasa de descuento:

$$R_t = 10 + 10 + 10 + 10 + 10 + \dots(\infty)$$

- ▶ Para evitar esto, aplicamos una tasa de descuento γ ($0 \leq \gamma \leq 1$).
- ▶ En vez de sumar todas las recompensas con el mismo peso, hacemos que las recompensas futuras valgan menos:

$$R_t = r_{t+1} + \gamma r_{t+2} + \gamma^2 r_{t+3} + \dots$$

- ▶ Si $\gamma=0.9$, entonces:

$$\begin{aligned} R_t &= 10 + 0.9 \cdot 10 + 0.9^2 \cdot 10 + 0.9^3 \cdot 10 + \dots \\ &= 10 + 9 + 8.1 + 7.29 + \dots \end{aligned}$$



- ▶ En este caso, la suma ya no se va al infinito porque cada término es cada vez más pequeño.

TAREAS EPISÓDICAS Y TAREAS CONTINUAS

- **Tareas episódicas:** Tienen un final claro (un episodio). Ejemplo: un juego que termina cuando el jugador gana.
- **Tareas continuas:** No tienen un final definido. Ejemplo: un robot en una fábrica que nunca deja de operar.

Si las recompensas recibidas después de un tiempo t se denotan como: $r_{t+1}, r_{t+2}, r_{t+3}, \dots$, lo que se quiere es maximizar la recompensa total (R_t), que en el caso más simple es:

$$R_t = r_{t+1} + r_{t+2} + r_{t+3} + \dots + r_T.$$

Si se tiene un punto terminal se llaman tareas *episódicas*, si no se tiene se llaman tareas *continuas*. En este último caso, la fórmula de arriba presenta problemas, ya que no podemos hacer el cálculo cuando T no tiene límite. Podemos usar una forma alternativa en donde se van haciendo cada vez más pequeñas las contribuciones de las recompensas más lejanas:

$$R_t = r_{t+1} + \gamma r_{t+2} + \gamma^2 r_{t+3} + \dots = \sum_{k=0}^{\infty} \gamma^k r_{t+k+1},$$

donde γ se conoce como la *razón de descuento* y está entre: $0 \leq \gamma < 1$. Si $\gamma = 0$ se trata de maximizar la recompensa total tomando en cuenta sólo las recompensas inmediatas.


ESTADOS ABSORBENTES

- ▶ En Frozen Lake si el personaje cae al lago o llega a la meta entra en un **estado absorbente**.
- ▶ Un **estado absorbente** es un estado final (estado terminal) en el que, una vez que el agente entra, no puede salir y las recompensas futuras se mantienen constantes (generalmente 0).
- ▶ Si el agente llega al **estado** s_{abs} , entonces:
 - ✓ Cualquier acción lo mantiene en s_{abs} (es decir, $P(s_{abs}|s_{abs},a) = 1$).
 - ✓ Las recompensas después de ese estado son 0 o constantes ($R(s_{abs},a)=0$ o alguna otra cantidad fija).



HORIZONTE FINITO E INFINITO

- ▶ Toda **tarea episódica** tiene, por definición, un horizonte finito. La longitud del episodio, T , es el horizonte.
 - ✓ **Horizonte fijo.** (ej: un juego que siempre dura 10 turnos)
 - ✓ **Horizonte estocástico/variable** (ej: un juego de ajedrez, donde el número de movimientos es finito pero desconocido de antemano). Aunque sea variable, sigue siendo finito.
- ▶ Si una tarea no tiene un estado terminal (**tareas continuas**), se modelan como si continuara para siempre. Un problema tiene horizonte infinito si el número de pasos que el agente toma no está acotado. En este caso, se utiliza un factor de descuento $\gamma \in [0, 1)$.



VALOR DE UN ESTADO

VALOR DE UN ESTADO

- ▶ Si lanzamos un dado de seis caras, el **valor esperado** del resultado es:

$$\mathbb{E}[X] = 1 \cdot \frac{1}{6} + 2 \cdot \frac{1}{6} + 3 \cdot \frac{1}{6} + 4 \cdot \frac{1}{6} + 5 \cdot \frac{1}{6} + 6 \cdot \frac{1}{6} = 3.5$$



- ▶ Esto significa que, en promedio, si lanzamos el dado muchas veces, el **valor esperado** del resultado será **3.5**.
- ▶ **Esperanza matemática**: es un valor que indica el resultado promedio que se espera obtener de una variable aleatoria.

$$\mathbb{E}[X] = \sum_i x_i P(x_i)$$

VALOR DE UN ESTADO



Fuente imagen: Cast away, 2000

VALOR DE UN ESTADO

- ▶ Ir a la derecha (30% de probabilidad) → Destino: una ciudad con una recompensa de 4 puntos.
- ▶ Ir a la izquierda (70% de probabilidad) → Destino: un bosque con una recompensa de 10 puntos.
- ▶ ¿Cuánto vale este cruce de caminos? No hay una única respuesta, porque depende de a dónde se elija ir.
- ▶ Una forma de responder es calcular el **valor esperado**, ponderando cada recompensa por su probabilidad:

$$V(\text{Cruce}) = 0.3(4) + 0.7(10) = 1.2 + 7 = 8.2$$


- ▶ ∴ el valor de este estado es un promedio ponderado de los posibles futuros.



Fuente imagen: Cast away, 2000

VALOR DE UN ESTADO

- ¿Cómo sé “cuán bueno” es un estado?



VALOR DE UN ESTADO

- ▶ La manera más simple de medir el valor de un estado de un MDP es obtener la recompensa inmediata que recibe el agente por moverse al estado siguiente s_{t+1} .


$$V(s_t) = r_{t+1} + \gamma r_{t+2} + \gamma^2 r_{t+3} + \dots + \gamma^{T-t-1} r_T$$

$$V(s_{t+1}) = r_{t+2} + \gamma r_{t+3} + \gamma^2 r_{t+4} + \dots + \gamma^{T-t-1} r_T$$

- ▶ Identificamos el patrón recursivo. El término $\gamma r_{t+2} + \gamma^2 r_{t+3} + \dots$ es muy similar a la función de valor del siguiente estado s_{t+1}
- ▶ Podemos sustituir $V(s_{t+1})$ en la expresión $V(s_t)$


$$V(s_t) = r_{t+1} + \gamma * [r_{t+2} + \gamma r_{t+3} + \dots + \gamma^{T-t-1} r_T]$$

$$V(s_t) = r_{t+1} + \gamma * V(s_{t+1})$$




VALOR DE UN ESTADO

- ▶ Si el agente se encuentra en un estado s , la política π es la estrategia o regla de cuál acción decide tomar el agente desde ese estado s .
- ▶ Una política podría ser elegir la mejor acción posible desde un estado s .




VALOR DE UN ESTADO



- ▶ Dado que estamos en un entorno incierto o de incertidumbre (porque no podemos predecir el estado siguiente debido a la existencia de probabilidades) el **valor de un estado** se puede calcular a partir del **valor esperado (esperanza)** por emplear una **política π** .
- ▶ La **esperanza** representa el valor promedio que podemos esperar obtener si estamos en el estado s_t , seguimos la **política π** , y consideramos todas las **posibles transiciones y recompensas**, ponderadas por sus probabilidades.

$$V_{\pi}(s_t) = \mathbb{E}_{\pi}[r_t + \gamma V_{\pi}(s_{t+1})]$$


VALOR DE UN ESTADO



- ▶ El valor de estar en el estado s_t siguiendo la política π es igual al valor esperado de la recompensa inmediata r_t mas el valor descontado del siguiente estado s_{t+1} , también evaluado siguiendo la política π .
- ▶ El valor esperado bajo la política π implica promediar sobre todas las posibles acciones que la política π podría recomendar en ese estado, y sobre todos los posibles estados siguientes que se podría alcanzar al tomar esas acciones.
- ▶ Esto se conoce como **Ecuación de Bellman para la evaluación de una política en un estado s_t** .

$$V_{\pi}(s_t) = \mathbb{E}_{\pi}[r_t + \gamma V_{\pi}(s_{t+1})]$$

VALOR DE UN ESTADO



- Demostración detallada de la **ecuación de Bellman** para determinar el valor de un estado s :

- 1. El retorno total (G_t) es la suma de recompensas futuras:

$$G_t = R_t + R_{t+1} + R_{t+2} + R_{t+3} + \dots$$


- 2. Si consideramos la **tasa de descuento** obtenemos la suma de recompensas futuras descontadas:

$$G_t = R_t + \gamma R_{t+1} + \gamma^2 R_{t+2} + \gamma^3 R_{t+3} + \dots$$

$$G_{t+1} = R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \gamma^3 R_{t+4} + \dots$$

$$G_t = R_t + \gamma G_{t+1}$$

VALOR DE UN ESTADO



- ▶ 3. Se aplica esperanza condicional a ambos miembros de la ecuación respecto a $s_t = s$:

$$G_t = R_t + \gamma G_{t+1}$$

$$\mathbb{E}[G_t \mid s_t = s] = \mathbb{E}[R_t + \gamma G_{t+1} \mid s_t = s]$$

- ▶ 4. Por propiedad de linealidad de la esperanza:

$$\mathbb{E}[G_t \mid s_t = s] = \mathbb{E}[R_t \mid s_t = s] + \gamma \mathbb{E}[G_{t+1} \mid s_t = s]$$


- ▶ 5. Por definición de valor de estado:

$$V(s) = \mathbb{E}[G_t \mid s_t = s]$$

- ▶ 6. Sustituyendo el segundo miembro en la ecuación anterior queda $V(s)$:

$$V(s) = \mathbb{E}[R_t \mid s_t = s] + \gamma \mathbb{E}[G_{t+1} \mid s_t = s]$$

VALOR DE UN ESTADO



- 7. En este punto la esperanza $E[G_{t+1}]$ debería estar expresada en términos de $V(s)$, por lo cual sabiendo que:

$$V(s_{t+1}) = \mathbb{E}[G_{t+1} \mid s_{t+1}]$$


- 8. Se aplica al segundo término $E[G_{t+1}]$ la regla de la esperanza iterada que establece que dadas 2 variables aleatorias X e Y , y a su vez dada una función $h(X, Y)$, la esperanza de h es igual a la esperanza condicional (anidada o iterada) respecto a ambas variables aleatorias X e Y :

$$\mathbb{E}[h(X, Y)] = \mathbb{E} \{ \mathbb{E} [h(X, Y) \mid X] \}$$

- En nuestro caso, la esperanza iterada de $E[G_{t+1}]$ es:

$$\mathbb{E}[G_{t+1} \mid s_t = s] = \mathbb{E}[\mathbb{E}[G_{t+1} \mid s_{t+1}] \mid s_t = s]$$

VALOR DE UN ESTADO



- 9. Sustituyendo la esperanza $\mathbb{E}[G_{t+1}]$ queda:

$$V(s_{t+1}) = \mathbb{E}[G_{t+1} | s_{t+1}]$$

$$\mathbb{E}[G_{t+1} | s_t = s] = \mathbb{E}[\mathbb{E}[G_{t+1} | s_{t+1}] | s_t = s]$$

$$\mathbb{E}[G_{t+1} | s_t = s] = \mathbb{E}[V(s_{t+1}) | s_t = s]$$

- Teníamos que $V(s)$ era:

$$V(s) = \mathbb{E}[R_t | s_t = s] + \gamma \mathbb{E}[G_{t+1} | s_t = s]$$

$$V(s) = \mathbb{E}[R_t | s_t = s] + \gamma \mathbb{E}[V(s_{t+1}) | s_t = s] \longrightarrow V_{\pi}(s_t) = \mathbb{E}_{\pi}[r_t + \gamma V_{\pi}(s_{t+1})]$$

- 10. Expandiendo la esperanza la **ecuación de Bellman** queda expresada como:

$$V(s) = \sum_{s'} P(s' | s, a) R(s, a, s') + \gamma \sum_{s'} P(s' | s, a) V(s')$$


$$V(s) = \sum_{s'} P(s' | s, a) [R(s, a, s') + \gamma V(s')]$$

$$v_{\pi}(s) = \sum_a \pi(a|s) \sum_{s', r} p(s', r | s, a) [r + \gamma v_{\pi}(s')],$$



INTERPRETACIÓN DE LA ECUACIÓN DE BELLMAN

- ▶ Ejemplo 1: Gridworld de 2x2
- ▶ Factor de descuento = 0.7

$$v_{\pi}(s) = \sum_a \pi(a|s) \sum_{s', r} p(s', r | s, a) [r + \gamma v_{\pi}(s')],$$



INTERPRETACIÓN DE LA ECUACIÓN DE BELLMAN




INTERPRETACIÓN DE LA ECUACIÓN DE BELLMAN

$$v_{\pi}(s) = \sum_a \pi(a|s) \sum_{s',r} p(s',r|s,a) [r + \gamma v_{\pi}(s')],$$

$$v_{\pi}(A) = \pi(a|A) [r + 0.7v_{\pi}(s')]$$

$$v_{\pi}(B) = \pi(a|B) [r + 0.7v_{\pi}(s')]$$



$$v_{\pi}(A) = \frac{1}{4} [5 + 0.7v_{\pi}(B)] + \frac{1}{4} [0 + 0.7v_{\pi}(C)] + \frac{1}{2} [0 + 0.7v_{\pi}(A)]$$

$$v_{\pi}(B) = \frac{1}{4} [0 + 0.7v_{\pi}(A)] + \frac{1}{4} [0 + 0.7v_{\pi}(D)] + \frac{1}{2} [5 + 0.7v_{\pi}(B)]$$

INTERPRETACIÓN DE LA ECUACIÓN DE BELLMAN

$$v_{\pi}(A) = \frac{1}{4} [5 + 0.7v_{\pi}(B)] + \frac{1}{4} [0 + 0.7v_{\pi}(C)] + \frac{1}{2} [0 + 0.7v_{\pi}(A)]$$

- ▶ De forma similar podemos calcular $V(C)$ y $V(D)$.
- ▶ Tenemos por lo tanto 4 ecuaciones con 4 incógnitas.


✓ A: 4.1666

✓ B: 6.0897

✓ C: 2.2436

✓ D: 4.1666

- ▶ **Estado B: 6.0897**: El hecho de que el valor $V(B)$ sea más alto que el resto indica que estar en B (y seguir la política prefijada) es más beneficioso a largo plazo.





INTERPRETACIÓN DE LA ECUACIÓN DE BELLMAN

► (Sutton et al., 2018)

$$v_{\pi}(s) = \sum_a \pi(a|s) \sum_{s', r} p(s', r | s, a) [r + \gamma v_{\pi}(s')],$$

► Ejemplo: **Robot repositor.**




INTERPRETACIÓN DE LA ECUACIÓN DE BELLMAN

► (Sutton et al., 2018)

$$v_{\pi}(s) = \sum_a \pi(a|s) \sum_{s', r} p(s', r | s, a) [r + \gamma v_{\pi}(s')],$$



- La **política** (π) que define la **probabilidad de tomar cada acción** en cada estado.
- La **dinámica del entorno** ($p(s', r | s, a)$) define las **probabilidades de transición** de un estado a otro ($s \rightarrow s'$) y las recompensas.
- El MDP en este problema se define por una tupla $M = \langle S, A, \Phi, R \rangle$, o bien $M = \langle S, A, T, R \rangle$.



INTERPRETACIÓN DE LA ECUACIÓN DE BELLMAN

► (Sutton et al., 2018)

$$v_{\pi}(s) = \sum_a \pi(a|s) \sum_{s',r} p(s',r|s,a) [r + \gamma v_{\pi}(s')],$$



INTERPRETACIÓN DE LA ECUACIÓN DE BELLMAN

► Resultados:


✓ alto: 43.0482

✓ medio: 36.1172

✓ bajo: 34.2194

► "alto" es el mejor estado. Esto tiene sentido, ya que indica que es más valioso a largo plazo mantener la góndola llena, incluso si no hay recompensas inmediatas por ello.

► "medio" es mejor que "bajo". También es lógico, ya que un estante a medio llenar es más valioso que un estante casi vacío.



EJEMPLO

- ▶ Supongamos que queremos modelar el comportamiento de un **robot** que repone mercadería en un supermercado.
- ▶ El **objetivo** es determinar cuál es el valor de cada **estado** dada una política específica.



EJEMPLO

► La góndola tiene 3 estados posibles:

- ✓ **Alto**: La góndola está llena de productos.
- ✓ **Medio**: La góndola tiene una cantidad moderada de productos.
- ✓ **Bajo**: La góndola está casi vacía.

► El robot tiene 2 acciones posibles:

- ✓ **Reponer**: El robot repone la góndola, llevándola al estado "**Alto**".
- ✓ **No Reponer**: El robot no hace nada.



EJEMPLO



- Las probabilidades de transición del MDP se expresan en forma tabular:

Estado Actual	Acción	Estado Siguiente	Probabilidad
Alto	Reponer	Alto	1
Alto	No Reponer	Medio	0.7
Alto	No Reponer	Bajo	0.3
Medio	Reponer	Alto	1
Medio	No Reponer	Bajo	0.8
Medio	No Reponer	Medio	0.2
Bajo	Reponer	Alto	1
Bajo	No Reponer	Agotado	0.9
Bajo	No Reponer	Bajo	0.1

EJEMPLO

- ▶ Las recompensas del MDP son:



Estado Actual	Acción	Recompensa
Alto	Reponer	5
Alto	No Reponer	8
Medio	Reponer	2
Medio	No Reponer	4
Bajo	Reponer	1
Bajo	No Reponer	0

EJEMPLO



► La política π (el comportamiento del robot) se define como:

- ✓ Si el estado es "Alto", el robot nunca repone.
- ✓ Si el estado es "Medio", el robot a veces repone (con probabilidad 0.5).
- ✓ Si el estado es "Bajo", el robot siempre repone.

Estado	Acción "Reponer"	Acción "No Reponer"
Alto	0	1
Medio	0.5	0.5
Bajo	1	0

CONCLUSION DEL EJEMPLO



- ▶ El robot nunca repone en "Alto", a veces repone en "Medio", y siempre repone en "Bajo", el valor de cada estado (es decir, la recompensa total esperada a largo plazo) es:
 - ✓ Alto: 47.90 (aproximadamente)
 - ✓ Medio: 44.44 (aproximadamente)
 - ✓ Bajo: 44.11 (aproximadamente)
- ▶ **Alto tiene el valor más alto:** Esto indica que, a largo plazo, es mejor estar en el estado "Alto" (con la góndola llena de productos) que en los estados "Medio" o "Bajo". Eso es lógico, ya que en ese estado se genera una muy buena cantidad de ventas.
- ▶ **La diferencia entre Medio y Bajo es pequeña:** Los estados "Medio" y "Bajo" tienen valores muy similares. Esto puede indicar que el costo de pasar del estado "Medio" al estado "Bajo" (perder ventas debido a la falta de productos) es similar al costo de siempre reponer cuando se está en el estado "Bajo".
- ▶ **Relación con la Política:** Es importante recordar que estos valores son específicos para la política que definimos. Si cambiáramos la política (por ejemplo, si el robot siempre repone en "Medio"), los valores de los estados también cambiarían.
- ▶ **No es la Política Óptima:** Estos valores no nos dicen cuál es la mejor política. Solo nos dicen **qué tan buena es la política que estamos evaluando**. Para encontrar la mejor política, necesitaríamos probar diferentes políticas y comparar sus valores.

REFERENCIAS BIBLIOGRÁFICAS Y WEB (I)

- ▶ S. Wang, S. Zhang, J. Zhang, R. Hu, X. Li, T. Zhang, et al., "Reinforcement Learning Enhanced LLMs: A Survey," arXiv preprint arXiv:2412.10400, 2024.
- ▶ J. Schulman, F. Wolski, P. Dhariwal, A. Radford, and O. Klimov, "Proximal Policy Optimization Algorithms," arXiv preprint arXiv:1707.06347, 2017.
- ▶ Hillier, F. S. Lieberman, G. J. (2010). Introducción a la Investigación de Operaciones.
- ▶ D. Guo et al., "DeepSeek-R1: Incentivizing reasoning capability in LLMs via reinforcement learning," arXiv preprint arXiv: 2501.12948, 2025.
- ▶ R. S. Sutton and A. G. Barto, Reinforcement Learning: An Introduction, 2nd ed. Cambridge, MA, USA: MIT Press, 2018.
- ▶ Cypher, A., & Halbert, D. C. (Eds.). (1993). Watch what I do: programming by demonstration. MIT press. ISO 690.
- ▶ Bain, M. and Sommut, C., 1999. A framework for behavioural cloning. Machine Intelligence 15, 15:103.
- ▶ Schaal, S. Learning from demonstration. In Advances in neural information processing systems, pages 1040-1046, 1997.
- ▶ S. Russell, "Learning agents for uncertain environments (extended abstract)," Proceedings of the 11th Annual Conference on Computational Learning Theory (COLT'98), Madison, WI, USA, 1998, pp. 101-103. doi: 10.1145/279943.279964.
- ▶ Ng, A. Y., & Russell, S. (2000). "Algorithms for inverse reinforcement learning." Proceedings of the Seventeenth International Conference on Machine Learning (ICML), vol. 1, no. 2, p. 2.

REFERENCIAS BIBLIOGRÁFICAS Y WEB (II)

- ▶ Howard, R. A. (1960). Dynamic programming and Markov processes.
- ▶ Puterman, M. L. Markov Decision Processes: Discrete Stochastic Dynamic Programming. Wiley (1994).
- ▶ Bellman, R. E. Dynamic Programming. Princeton University Press (1957).